

Technische Hochschule Nürnberg Georg Simon Ohm
Fakultät Elektrotechnik Feinwerktechnik Informationstechnik

Implementierung eines fiducialbasierten Lokalisierungssystems für Luftfahrzeuge im Innenraum

Masterarbeit im Studiengang Elektronische und Mechatronische Systeme
Vertiefungsrichtung Automatisierungstechnik

Hannes Müller
3796115

Betreuer: Prof. Dr. rer. nat. Pfitzner
Betreuer: Noch nicht sicher

Abgabe: Nürnberg, 10. Juni 2026
Sommersemester 2026

Abstract

This thesis describes the development of a visual localization system for unmanned aerial vehicles based on fiducial markers in indoor environments. The Robot Operating System 2 is used as the middleware framework; AprilTags are used as the marker framework. The system uses the RGB images from two cameras as its input data source—one facing forward and one facing downward. The image processing and navigation calculations are performed by a mini-computer mounted on the aircraft. Position determination is based on the mapping of fiducial markers using simultaneous localization and mapping. For the extrinsic calibration of the cameras, a custom-developed algorithm for determining the respective transformation matrix is described. Position determination itself is achieved by detecting the previously mapped markers and calculating the poses of the camera lenses. The position data from both sensors are processed, fused into a single pose, and transmitted to the flight controller. The overall system enables GPS-independent positioning designed for indoor use. Finally, a prototype application is presented that can be used to control the aircraft.

Kurzfassung

Diese Arbeit beschreibt die Entwicklung eines visuellen Lokalisierungssystems für unbemannte Luftfahrzeuge auf Basis von Fiducial-Markern im Innenraum. Als Middleware-Framework wird das Robot Operating System 2 verwendet; als Marker-Framework kommen AprilTags zum Einsatz. Das System nutzt die RGB-Bilder zweier Kameras als Eingangsdatenquelle – eine frontal und eine nach unten ausgerichtet. Die Berechnungen zur Bildverarbeitung sowie zur Navigation werden durch einen am Luftfahrzeug montierten mini-Computer durchgeführt. Grundlage der Positionsbestimmung bildet die Kartierung der Fiducial-Marker mittels Simultaner Lokalisierung und Kartierung. Zur extrinsischen Kalibrierung der Kameras wird ein eigens entwickelter Algorithmus zur Bestimmung der jeweiligen Transformationsmatrix beschrieben. Die Positionsbestimmung selbst erfolgt durch die Erkennung der zuvor kartierten Marker sowie die Berechnung der Posen der Kameraoptiken. Die Positionsdaten beider Sensoren werden aufbereitet, zu einer einzigen Pose fusioniert und an den Flugcontroller übermittelt. Das Gesamtsystem ermöglicht eine GPS-unabhängige Lokalisierung, die für den Einsatz in Innenräumen ausgelegt ist. Abschließend wird eine prototypische Anwendung vorgestellt, die zur Steuerung des Luftfahrzeugs eingesetzt werden kann.

Inhaltsverzeichnis

Abstract	III
Kurzfassung	IV
Abkürzungsverzeichnis	VII
1 Einleitung	1
2 Theoretische Grundlagen	2
2.1 Grundlagen Unbemannter Flugroboter	2
2.1.1 Mechanischer Aufbau am Beispiel der Holybro X650	2
2.1.2 Vergleich von Welt-, Roboter-, Kamera- und Fiducialkoordinatensystem	2
2.2 Repräsentation von Position und Orientierung	4
2.2.1 Quaternionen	4
2.2.2 Rodrigues-Parameter	6
2.3 Transformation von Koordinatensystemen	6
2.4 Sensorsysteme	7
2.5 Extended Kallman Filter	8
2.6 Pixhawk 6X	9
2.6.1 Sensorik	10
2.6.2 Schnittstellen	10
2.6.3 EKF2 – Zustandsschätzung und Sensorfusion	11
2.6.4 Betriebssystem	11
2.6.5 Robot Operating System 2 (ROS2)	11
2.6.5.1 Nodes und Topics	12
2.6.5.2 Bag-Dateien	12
2.6.5.3 TF2 – Koordinatentransformationen	12
3 Stand der Technik	13
3.1 GNSS-freie Lokalisierung von UAVs	13
3.1.1 Absolute Lokalisierung	13
3.1.2 Relative Lokalisierung	14
3.1.2.1 Dead Reckoning Localization	14
3.1.2.2 Visuelle Odometrie und optischer Fluss	14
3.1.3 Simultane Lokalisierung und Kartierung	15
3.1.3.1 Phasen optimierungsbasierter SLAM Methoden	15
3.1.3.2 Faktorgraph	16
3.1.3.3 SLAM-Varianten	17
3.2 Fiducial-Marker-Systeme	18
3.2.0.1 ARTag	18
3.2.0.2 AprilTag	19
3.2.0.3 ArUco	19
3.2.0.4 STag	19
3.2.0.5 Detektion	19

4	Systembeschreibung	21
4.1	Aufbau der Testumgebung	21
4.2	Softwarearchitektur	21
4.3	Systempipeline	21
4.3.1	elektrischer Aufbau der Holybro X650 mit Pixhawk 6X	21
5	Implementierung der Kartierung	22
5.1	Datensatz- und Objektauswahl	22
5.2	Training der Modelle	22
5.2.1	Yolov8 Training	22
6	Ansteuerung des KUKA iiwa 7 R800	23
6.1	Kommunikationsschnittstellen	23
6.2	Greifpunktberechnung	23
6.2.1	Vortrainiertes Modell Dexnet	23
6.2.2	Segmentierung mithilfe der Bounding Boxen und dbscan	23
6.2.3	Segmentierungslogik je Objekt	23
7	Systemintegration	24
8	Evaluation des Greifens	25
8.1	Erfolgskriterien - Erfolgsquote und Fehlerrate	25
8.2	Erkennungsgenauigkeit	25
8.3	Positioniergenauigkeit	25
8.4	Zeitliche Performance und Echtzeitfähigkeit	25
9	Zusammenfassung und Ausblick	26
10	Anhang	34

Abkürzungsverzeichnis

DRL	Dead Reckoning Localization
EKF	Extended Kalman Filter
EKF2	Extended Kalman Filter 2
EMA	Exponential Moving Average
FMU	Flight Management Unit
g2o	General Graph Optimization
GNSS	Global Navigation Satellite System
GPS	Global Positioning System
GTSAM	Georgia Tech Smoothing and Mapping
IEKF	Invariant Extended Kalman Filter
IMU	Inertial Measurement Unit
LiDAR	Light Detection and Ranging
LiPo	Lithium-Polymer-Akku
PX4	Pixhawk
RANSAC	Random Sample Consensus
ROS2	Robot Operating System 2
SLAM	Simultaneous Localization and Mapping
UAV	Unmanned Aerial Vehicle
UDP	User Datagram Protocol
VIO	Visuelle Inertial Odometrie
VO	Visuelle Odometrie
vSLAM	Visual SLAM

1 Einleitung

Die vorliegende Arbeit beschäftigt sich mit der Entwicklung eines Fiducial-basierten Systems zur Positionserkennung eines Flugroboters im Innenraum. Als Grundgerüst des Systems dient eine Holybro X650 Unmanned Aerial Vehicle (UAV), welche mit einem Pixhawk 6X Flight Controller ausgestattet ist. Es wird auf die Parametrierung und Kalibrierung des Flight Controllers eingegangen, sodass die vom implementierten System bereitgestellte Position mit den übrigen Sensordaten durch einen Extended Kalman Filter fusioniert werden kann. Der Flight Controller ist seriell mit einem Jetson Orin NX verbunden, auf welchem ein Robot Operating System 2 (ROS2) Humble System läuft, das die Implementierung der Algorithmen sowie die Kommunikation zwischen den Komponenten ermöglicht. Die Kommunikation zwischen dem Jetson Orin NX und dem Pixhawk 6X wird über das MAVROS-Paket realisiert.

Als Sensoren zur Erkennung der Fiducials werden zwei Logitech-Kameras am Flugroboter angebracht und mit dem Jetson Orin NX verbunden, wobei eine Kamera nach unten und eine nach vorne ausgerichtet ist. Zur Auswahl der geeigneten Kameras werden die Logitech C920 Pro und die Logitech C922 Pro anhand definierter Bewertungskriterien verglichen, die mithilfe eines Paarweisen Vergleichs gewichtet und anschließend in einer Nutzwertanalyse bewertet werden. Aufgrund des Ergebnisses wird die Logitech C920 als nach vorne gerichtete Kamera und die Logitech C922 als nach unten gerichtete Kamera ausgewählt. Die Kameras werden mittels extrinsischer Kalibrierung geometrisch aufeinander abgestimmt.

Um eine zuverlässige Positionserkennung zu gewährleisten, werden AprilTags, ArUco-Marker und WhyCon-Marker ebenfalls anhand einer gewichteten Nutzwertanalyse verglichen. AprilTags gehen als geeignetstes Fiducial hervor. Für die Kartierung des Innenraums wird die Erkennung der AprilTags über die OpenCV-Bibliothek implementiert, während die Live-Positionierung durch die hardwarebeschleunigte NVIDIA Isaac ROS2 AprilTag-Erkennung auf dem Jetson Orin NX realisiert wird.

Die Kartierung des Innenraums erfolgt auf Basis einer Faktorgrafen-basierten Zustandsschätzung. Ein erster Ansatz der Echtzeit-Kartierung wird aufgrund der zu hohen Rechenlast verworfen. In einem zweiten Ansatz wird die Kartierung offline auf einem separaten Computer unter ROS2 Jazzy durchgeführt. Die erstellten Karten werden anhand der realen Umgebung bewertet und mit verschiedenen Parametern optimiert.

Die Positionserkennung relativ zur erstellten Karte wird ebenfalls in zwei Varianten untersucht. Zum einen die Faktorgrafen-basierte Zustandsschätzung, zum anderen die direkte geometrische Posenschätzung. Aufgrund der geringeren Rechenlast und der verfügbaren hardwarebeschleunigten NVIDIA Isaac AprilTag-Unterstützung wird die direkte geometrische Posenschätzung eingesetzt. Die erkannten Tags werden mithilfe von Exponential Moving Average (EMA)-Glättung, Medianfilterung, Random Sample Consensus (RANSAC) und Kovarianzschätzung aufbereitet und dem Flight Controller bereitgestellt.

Abschließend werden Probleme und Schwachstellen des Systems diskutiert sowie Verbesserungspotenziale aufgezeigt.

2 Theoretische Grundlagen

Zum besseren Verständnis der vorliegenden Arbeit werden im folgenden Kapitel die theoretischen Grundlagen erläutert. Es werden grundlegende Begriffe aus den Bereichen der Robotik, der Sensorik sowie der visuellen Navigation eingeführt. Darüber hinaus wird gesondert auf den verwendeten Flugcontroller, die zugrundeliegenden Koordinatensysteme sowie die relevanten Transformationen eingegangen.

2.1 Grundlagen Unbemannter Flugroboter

Unter einem unbemannten Luftfahrzeug UAV, umgangssprachlich auch als Drohne bezeichnet, versteht man ein Fluggerät, welches ohne einen menschlichen Piloten an Bord betrieben werden kann. Dabei können UAVs entweder ferngesteuert von einem menschlichen Operator oder vollständig autonom durch einen bordeigenen Computer geführt werden. Die Anfänge unbemannter Luftfahrzeuge reichen bis in die 1910er Jahre zurück, wo sie vorrangig für militärische Zwecke eingesetzt wurden. Ab den 2000er Jahren fanden UAVs zunehmend Eingang in zivile Anwendungsgebiete, wie beispielsweise die Katastrophenhilfe [1, S. 1–3].

2.1.1 Mechanischer Aufbau am Beispiel der Holybro X650

Grundrahmen: Der Grundrahmen eines UAV dient als mechanische Basis für die Montage aller weiteren Komponenten. Das Design des Rahmens beeinflusst maßgeblich die Flugeigenschaften des Geräts. Das in dieser Arbeit verwendete Modell ist als Senkrechtstarter konzipiert und basiert auf einem X-förmigen Quadcopter-Rahmen. Die wesentlichen Bestandteile des Rahmens umfassen die Ausleger, das Landegestell sowie die zentrale Montageplattform für die Elektronik. Die Holybro X650 weist eine Diagonale von 650 mm auf. Abbildung 2.2 zeigt ein Bild der Holybro X650. [2] [3]

Antriebssystem: Das Antriebssystem besteht aus vier Elektromotoren, die jeweils an einem der Ausleger montiert sind. An den Motoren sind Propeller befestigt, welche den erforderlichen Auftrieb erzeugen.

Flugcontroller: Der Flugcontroller bildet das zentrale Steuerungselement eines UAV. Er setzt eingehende Steuerbefehle in konkrete Ansteuersignale um, die an die Motoren weitergeleitet werden. In Kapitel ?? wird näher auf den verwendeten Flugcontroller eingegangen.

Energieversorgung: Die Energieversorgung erfolgt über einen Lithium-Polymer-Akku (LiPo). Dieser versorgt die Steuerelektronik als auch die Motoren.

Nutzlast: Das maximale Abfluggewicht der Holybro X650 beträgt 6,3 kg, wobei der flugfertige Grundrahmen bereits ein Eigengewicht von 4,3 kg aufweist. Daraus ergibt sich eine maximale Nutzlast von 2 kg (ohne Akku) [3].

2.1.2 Vergleich von Welt-, Roboter-, Kamera- und Fiducialkoordinatensystem

Dieses Kapitel behandelt die verschiedenen Koordinatensysteme, die in dieser Arbeit relevant sind. Dabei wird zwischen dem Welt-, Roboter-, Kamera- und Fiducialkoordinatensystem unterschieden.

Weiterhin werden die grundlegenden Konzepte zur Repräsentation von Position und Orientierung im Raum erläutert.

Ein Koordinatensystem ist ein mathematisches Konstrukt, das zur eindeutigen Beschreibung der Lage von Punkten im Raum verwendet wird. Zur Beschreibung von Bewegungen ist die Festlegung eines Koordinatensystems von entscheidender Bedeutung. Es besteht aus einem Bezugspunkt, dem Ursprung, sowie drei orthogonalen Achsen, die als X-, Y- und Z-Achse bezeichnet werden. In dieser Arbeit wird standardmäßig das rechtshändige Koordinatensystem verwendet [4, S. 17]. Mathematisch wird der Zusammenhang durch

$$\mathbf{Z} = \mathbf{X} \times \mathbf{Y} \quad (2.1)$$

dargestellt. In dieser Arbeit werden die Achsen entsprechend des informellen Industriestandards wie folgt dargestellt: X-Achse in Rot, Y-Achse in Grün und Z-Achse in Blau. Ein Überblick über die in dieser Arbeit verwendeten Koordinatensysteme ist in Abbildung 2.1 dargestellt.




Abbildung 2.1: Vergleich der Koordinatensysteme [3]

Das Weltkoordinatensystem dient als globaler Referenzrahmen, in dem die Position aller Objekte beschrieben wird. Der Ursprung dieses Koordinatensystems kann frei gewählt werden und wird durch die Variable O_0 repräsentiert. Die Achsen werden durch X_0 , Y_0 und Z_0 dargestellt [5, S. 4].

Das UAV-Koordinatensystem ist in der Regel vom Hersteller vorgegeben und richtet sich in diesem konkreten Fall nach dem Flugregler. In der zugehörigen Dokumentation wird angegeben, dass die X-Achse (X_u) nach vorne, die Y-Achse (Y_u) nach rechts und die Z-Achse (Z_u) nach unten zeigt. Der Ursprung dieses Koordinatensystems (O_u) befindet sich im Zentrum des Flugreglers [6].

Das Kamerakoordinatensystem ist in der Regel so definiert, dass die Z-Achse (Z_c) entlang der optischen Achse der Kamera zeigt, die X-Achse (X_c) nach rechts auf der Bildebene und die Y-Achse (Y_c) nach unten auf der Bildebene zeigt. Der Ursprung (O_c) befindet sich im optischen Zentrum der Kamera [7, S. 44].

Das Fiducialkoordinatensystem ist in dieser Arbeit so definiert, dass sich der Ursprung (O_f) im Mittelpunkt der Fiducialmarke befindet. Die Z-Achse (Z_f) zeigt senkrecht aus der Markerebene heraus, die X-Achse (X_f) zeigt nach rechts in der Markerebene und die Y-Achse (Y_f) zeigt nach oben in der Markerebene.

2.2 Repräsentation von Position und Orientierung

In diesem Unterkapitel wird das verwendete UAV als starrer Körper betrachtet. Die vollständige Beschreibung der Lage eines starren Körpers im Raum erfolgt durch seine Position und Orientierung [8, S. 12].

Die Position eines Körpers wird durch den Vektor

$$\mathbf{p} = (x, y, z)^T \quad (2.2)$$

beschrieben, wobei die Koordinaten einem bestimmten Koordinatensystem zugeordnet sind.

Die Orientierung eines Körpers kann auf verschiedene Weisen dargestellt werden. Im Folgenden werden die zum Verständnis dieser Arbeit relevanten Darstellungsformen erläutert. Grundsätzlich kann sich ein Körper um drei Achsen drehen, was durch die Euler-Winkel Roll (ϕ), Pitch (θ) und Yaw (ψ) beschrieben wird. Abbildung 2.2 zeigt die Definition dieser Winkel am Beispiel der Holybro X650. Die Pfeilrichtung entspricht der positiven Drehrichtung im rechtshändigen Koordinatensystem.




Abbildung 2.2: Roll, Pitch und Yaw am Beispiel Holybro X650 [3]

2.2.1 Quaternionen

Die Orientierung im Raum kann ebenfalls als Quaternion dargestellt werden. Quaternionen bieten gegenüber Euler-Winkeln den Vorteil, dass sie keine Singularitäten (Gimbal Lock) aufweisen. Qua-

ternionen stellen eine Erweiterung des komplexen Zahlenraums dar und werden durch Gleichung 2.3 definiert [8].

$$\mathbf{q} = w + ix + jy + kz \quad (2.3)$$

wobei die Komponenten w, x, y und z reelle Skalare sind und i, j sowie k die imaginären Einheiten darstellen. Die imaginären Einheiten erfüllen die folgenden Multiplikationsregeln:

$$ii = jj = kk = ijk = -1 \quad (2.4)$$

$$ij = k, \quad jk = i, \quad ki = j \quad (2.5)$$

$$ji = -k, \quad kj = -i, \quad ik = -j \quad (2.6)$$

Addition und Multiplikation von Quaternionen sind durch die Gleichungen 2.7 und 2.8 definiert.

$$q_1 + q_2 = (w_1 + w_2) + i(x_1 + x_2) + j(y_1 + y_2) + k(z_1 + z_2) \quad (2.7)$$

$$\begin{aligned} q_1 \cdot q_2 = & (w_1w_2 - x_1x_2 - y_1y_2 - z_1z_2) \\ & + i(w_1x_2 + x_1w_2 + y_1z_2 - z_1y_2) \\ & + j(w_1y_2 - x_1z_2 + y_1w_2 + z_1x_2) \\ & + k(w_1z_2 + x_1y_2 - y_1x_2 + z_1w_2) \end{aligned} \quad (2.8)$$

Das Einheitsquaternion $\mathbf{q}$ beschreibt eine Rotation um den Winkel ϕ um eine normierte Rotationsachse $\mathbf{v} = (v_x, v_y, v_z)^T$ und wird durch Gleichung 2.9 beschrieben [9].

$$\mathbf{q} = \left(\cos \frac{\phi}{2}, \mathbf{v} \cdot \sin \frac{\phi}{2} \right) = \left(\cos \frac{\phi}{2}, v_x \sin \frac{\phi}{2}, v_y \sin \frac{\phi}{2}, v_z \sin \frac{\phi}{2} \right) \quad (2.9)$$

Die Konjugation eines Quaternions ist analog zu den komplexen Zahlen durch Gleichung 2.10 definiert.

$$\bar{\mathbf{q}} = (w, -x, -y, -z) \quad (2.10)$$

Für die Rotation eines beliebigen Punktes $\mathbf{p} = (0, p_x, p_y, p_z)$ mittels eines Rotationsquaternions $\mathbf{q}$ wird Gleichung 2.11 angewendet. [10, S. 112]

$$\mathbf{p}' = \mathbf{q} \cdot \mathbf{p} \cdot \bar{\mathbf{q}} \quad (2.11)$$

Die Normalisierung eines Quaternions erfolgt gemäß

$$\mathbf{q} \leftarrow \frac{\mathbf{q}}{\|\mathbf{q}\|}, \quad \|\mathbf{q}\| = \sqrt{x^2 + y^2 + z^2 + w^2} \quad (2.12)$$

2.2.2 Rodrigues-Parameter

Ein Rodrigues-Vektor ist eine alternative Möglichkeit, eine Rotation im Raum zu beschreiben. Die Rotation wird durch einen Vektor $\mathbf{r} = (r_x, r_y, r_z)^T$ beschrieben, dessen Richtung die Rotationsachse angibt und dessen Betrag den Rotationswinkel repräsentiert [11]. Der Rotationswinkel ϕ ergibt sich aus dem Betrag des Rodrigues-Vektors gemäß Gleichung 2.13 und wird gegen den Uhrzeigersinn um die Rotationsachse gemessen. [12]

$$\phi = \|\mathbf{r}\| = \sqrt{r_x^2 + r_y^2 + r_z^2} \quad (2.13)$$

Für die Umrechnung in ein Quaternion muss die Rotationsachse $\mathbf{v}$ zunächst normiert werden:

$$\hat{\mathbf{v}} = \frac{\mathbf{r}}{\phi} = \left(\frac{r_x}{\phi}, \frac{r_y}{\phi}, \frac{r_z}{\phi} \right)^T \quad (2.14)$$

Die Umrechnung in ein Einheitsquaternion lässt sich folgendermaßen beschreiben:

$$\mathbf{q} = \left(\hat{v}_x \cdot \sin \frac{\phi}{2}, \hat{v}_y \cdot \sin \frac{\phi}{2}, \hat{v}_z \cdot \sin \frac{\phi}{2}, \cos \frac{\phi}{2} \right) \quad (2.15)$$

Eingesetzt ergibt sich:

$$\mathbf{q} = \left(\frac{r_x}{\phi} \sin \frac{\phi}{2}, \frac{r_y}{\phi} \sin \frac{\phi}{2}, \frac{r_z}{\phi} \sin \frac{\phi}{2}, \cos \frac{\phi}{2} \right) \quad (2.16)$$

Mit Hilfe der Gleichungen 2.13 und 2.16 lässt sich die Umrechnung von Rodrigues-Parametern in ein Quaternion durchführen.

2.3 Transformation von Koordinatensystemen

Um die genaue Position des UAVs bestimmen zu können, sind mehrere Koordinatentransformationen notwendig. Transformationen sind sowohl bei der Lokalisierung im Raum als auch bei der extrinsischen Kalibrierung der Kameras erforderlich. Es ist möglich, einen Punkt ${}^a\mathbf{r}$, ausgedrückt relativ zum Koordinatensystem a , relativ zum Koordinatensystem b auszudrücken, sofern Position und Orientierung des Systems a relativ zum System b bekannt sind. Ziel ist es, aus dieser Beziehung eine Transformationsmatrix abzuleiten, die zugleich die Rotation und die Translation zwischen den beiden Systemen beschreibt. [9, S. 16–17]. Die Orientierung des Systems a relativ zum System b wird durch eine Rotationsmatrix ${}^b\mathbf{R}_a$ beschrieben. Die Lage des Ursprungs von a relativ zu b wird durch den Translationsvektor ${}^b\mathbf{t}_a \in \mathbb{R}^3$ angegeben. Ein im System a ausgedrückter Punkt ${}^a\mathbf{r}$ lässt sich dann mittels

$${}^b\mathbf{r} = {}^b\mathbf{R}_a {}^a\mathbf{r} + {}^b\mathbf{t}_a \quad (2.17)$$

in das System b überführen. Diese Vorschrift kombiniert eine Drehung und eine anschließende Verschiebung in einem einzigen Schritt. Durch Einführung homogener Koordinaten ${}^a\tilde{\mathbf{r}} = \begin{bmatrix} {}^a\mathbf{r}^T & 1 \end{bmatrix}^T$ lässt sich die Drehung und Verschiebung in eine einzige Matrix überführen. Die zugehörige *homoge-*

ne Transformationsmatrix ${}^b\mathbf{T}_a \in \text{SE}(3)$ ist definiert als

$${}^b\mathbf{T}_a = \begin{bmatrix} {}^b\mathbf{R}_a & {}^b\mathbf{t}_a \\ \mathbf{0}^\top & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 4}. \quad (2.18)$$

Damit lässt sich Gleichung (2.17) kompakt schreiben als

$${}^b\tilde{\mathbf{r}} = {}^b\mathbf{T}_a {}^a\tilde{\mathbf{r}}. \quad (2.19)$$

Die Rotationsmatrix ${}^b\mathbf{R}_a$ kann dabei aus einem Einheitsquaternion $\mathbf{q} = (w, x, y, z)$ berechnet werden:

$$R(\mathbf{q}) = \begin{bmatrix} 1 - 2y^2 - 2z^2 & 2xy - 2zw & 2xz + 2yw \\ 2xy + 2zw & 1 - 2x^2 - 2z^2 & 2yz - 2xw \\ 2xz - 2yw & 2yz + 2xw & 1 - 2x^2 - 2y^2 \end{bmatrix}. \quad (2.20)$$

Eine wesentliche Eigenschaft homogener Transformationsmatrizen ist ihre Verkettbarkeit. Sind die Transformationen ${}^c\mathbf{T}_b$ (von b nach c) und ${}^b\mathbf{T}_a$ (von a nach b) bekannt, so ergibt sich die direkte Transformation von a nach c durch

$${}^c\mathbf{T}_a = {}^c\mathbf{T}_b {}^b\mathbf{T}_a. \quad (2.21)$$

2.4 Sensorsysteme

Zum besseren Verständnis der Arbeit werden in diesem Unterkapitel die relevanten Sensortypen vorgestellt.

Die zentrale Sensoreinheit für ein UAV ist die Inertial Measurement Unit (IMU), welche Beschleunigungen und Winkelgeschwindigkeiten misst. Die IMU besteht typischerweise aus einem 3-Achsen-Beschleunigungssensor und einem 3-Achsen-Gyroskop. In einigen Fällen kann auch ein 3-Achsen-Magnetometer integriert sein, um die Orientierung relativ zum Erdmagnetfeld zu bestimmen. Ein weiterer Sensortyp ist das Barometer zur Bestimmung der Höhe, indem es den aktuellen Luftdruck misst. Weiterhin kann auch die Motordrehzahl oder Motorlast als Sensorinformation genutzt werden, um Rückschlüsse auf den aktuellen Bewegungszustand zu ziehen [8]. All diese Sensoren liefern nicht direkt die Position oder Orientierung des Roboters, reagieren jedoch schnell auf Bewegungsänderungen. Jeder dieser Sensoren ist mit einer gewissen Messunsicherheit behaftet, die durch Rauschen, Kalibrierungsfehler oder Umwelteinflüsse unterschiedlich stark ausgeprägt sein kann. Diese Messunsicherheiten lassen sich grundsätzlich in deterministische und stochastische Fehleranteile unterteilen [13]. Ein wesentlicher deterministischer Fehler ist der Bias, ein systematischer Messfehler in Form eines konstanten Versatzes, der die Messung auch dann verfälscht, wenn keine physikalische Größe anliegt. So gibt beispielsweise ein ruhendes Gyroskop trotz fehlender Drehung einen von null verschiedenen Wert aus. Dem gegenüber steht das Rauschen als stochastischer, mittelwertfreier Fehleranteil. Die Sensorfusion, also die Kombination der Daten mehrerer Sensoren, ermöglicht es, die Genauigkeit der Messungen zu verbessern [14].

Die Integration dieser Sensordaten über die Zeit ermöglicht es, die Bewegung des Roboters zu verfolgen und eine Schätzung seines Zustands zu erhalten, was als Odometrie bezeichnet wird. Da die

Sensoren, wie zuvor beschrieben, trotz Fusion fehlerbehaftet sind, führt die Integration über die Zeit zu einer zunehmenden Unsicherheit. Die Odometrie eines Flugroboters ist besonders herausfordernd, da sich das UAV in drei Dimensionen frei bewegt. Der zunehmende Fehler der Odometrie kann durch die Verwendung von externen Referenzen, wie Global Positioning System (GPS), korrigiert werden.

2.5 Extended Kallman Filter

In dieser Arbeit wird nicht näher auf die Sensorfusion eingegangen, da der Extended Kalman Filter (EKF) bereits vollständig im Flugcontroller implementiert ist. Auch die speziell im Pixhawk (PX4) zugrundeliegenden mathematischen Modelle werden nicht weiter erläutert. Zum Verständnis der Positionsbestimmung sowie der Parametrierung des EKF ist es jedoch notwendig, die Grundlagen des Kalman-Filters zu kennen.

Ein Kalman-Filter ist ein Algorithmus zur Schätzung des Zustands eines dynamischen Systems durch die Kombination von Vorhersagen aus einem mathematischen Modell und Messungen von Sensoren [15]. Der EKF ist ein rekursiver Filter, wodurch er kontinuierlich neue Messwerte verarbeiten kann. Im Folgenden wird der grundlegende Aufbau des Filters geschildert. Der Filter besteht im Wesentlichen aus drei Phasen. In der Literatur wird zwischen zwei Arten von Zustandsschätzungen unterschieden: Der *Prior* $(\cdot)^-$ bezeichnet die durch das Systemmodell vorhergesagte Schätzung vor der Einbeziehung einer neuen Messung. Der *Posterior* $(\cdot)^+$ bezeichnet die korrigierte Schätzung nach der Einbeziehung der Messung [16]. Der Operator $(\hat{\cdot})$ kennzeichnet dabei stets eine Schätzgröße – $\hat{x}$ ist demnach eine Schätzung des wahren Zustands x [16].

Zu Beginn muss eine Anfangsbedingung festgelegt werden. Hierfür benötigt das System einen initialen Zustandsschätzwert $\hat{x}_0^+$ sowie die zugehörige Unsicherheit in Form der Zustandskovarianzmatrix P_0^+ [16]. In der Prädiktionsphase wird der Zustand des Systems zum nächsten Zeitpunkt auf Basis eines mathematischen Modells berechnet. Der Zustand $\hat{x}_k^-$ wird dabei aus dem vorherigen Zustand $\hat{x}_{k-1}^+$ und der Steuereingabe u_{k-1} über die nichtlineare Modellfunktion f prädiziert:

$$\hat{x}_k^- = f(\hat{x}_{k-1}^+, u_{k-1}) \quad (2.22)$$

Gleichzeitig wird die Zustandskovarianzmatrix P_k^- fortgeschrieben, die die Unsicherheit der Schätzung beschreibt. Sie wächst in dieser Phase durch das Prozessrauschen Q_{k-1} an:

$$P_k^- = F_{k-1} P_{k-1}^+ F_{k-1}^T + Q_{k-1} \quad (2.23)$$

Dabei ist F_{k-1} die Jacobi-Matrix der Modellfunktion f , die durch Linearisierung um den aktuellen Schätzwert gebildet wird. Das Prozessrauschen Q beschreibt, wie stark das Systemmodell vom realen Verhalten abweicht: Ein hoher Wert bedeutet ein geringeres Vertrauen in das Modell.

In der Korrekturphase wird der prädizierte Zustand auf Basis eines Messwerts z_k korrigiert. Zunächst wird der Kalman-Gain K_k berechnet, der bestimmt, wie stark die Messung in die Schätzung einfließt:

$$K_k = P_k^- H_k^T (H_k P_k^- H_k^T + R_k)^{-1} \quad (2.24)$$

Hierbei ist $\mathbf{H}_k$ die Jacobi-Matrix der Messfunktion h und $\mathbf{R}_k$ die Messrauschkovarianzmatrix. $\mathbf{R}$ beschreibt die Unsicherheit der Sensormessungen: Ein hoher Wert führt zu einem geringeren Vertrauen in die Messung und damit zu einer schwächeren Korrektur. Der Kalman-Gain gewichtet folglich Modellvorhersage und Messung anhand ihrer jeweiligen Unsicherheiten.

Anschließend wird der korrigierte Zustand $\hat{\mathbf{x}}_k^+$ aus dem prädizierten Zustand und der gewichteten Differenz zwischen tatsächlicher Messung $\mathbf{z}_k$ und erwarteter Messung $h(\hat{\mathbf{x}}_k^-)$ – der sogenannten Innovation – berechnet:

$$\hat{\mathbf{x}}_k^+ = \hat{\mathbf{x}}_k^- + \mathbf{K}_k \left(\mathbf{z}_k - h(\hat{\mathbf{x}}_k^-) \right) \quad (2.25)$$

Abschließend wird die Zustandskovarianzmatrix aktualisiert und durch die Einbeziehung der Messung reduziert:

$$\mathbf{P}_k^+ = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_k^- \quad (2.26)$$

Die aktualisierten Größen $\hat{\mathbf{x}}_k^+$ und $\mathbf{P}_k^+$ dienen im nächsten Zeitschritt wiederum als Ausgangswerte der Prädiktionsphase, wodurch sich der rekursive Charakter des Filters ergibt [16].

2.6 Pixhawk 6X

PX4 ist ein Open-Source-Autopilot-Flugstack, der die Flugsteuerung, Zustandsschätzung und Kommunikation eines UAV übernimmt. Das Pixhawk-Projekt wurde ursprünglich als studentisches Projekt an der ETH Zürich gestartet [17] und hat sich seitdem zu einem weit verbreiteten Open-Source-Standard in der UAV-Forschung und -Industrie entwickelt. Der in dieser Arbeit verwendete Pixhawk 6X basiert auf dem Pixhawk FMUv6X-Standard und wurde von Holybro in Zusammenarbeit mit dem PX4-Entwicklerteam entwickelt.[18] Er bildet das zentrale Steuerungselement des verwendeten UAV.

Der Flugcontroller besteht aus zwei Teilen: dem Baseboard V2A und dem FMU-6X-Modul. Das Flight Management Unit (FMU)-Modul wird auf das Baseboard aufgesteckt und verschraubt. Die Komponenten sind in Abbildung 2.3 dargestellt. Im weiteren Verlauf der Arbeit wird dieser Zusammenschluss als Flugcontroller bezeichnet. Das FMU stellt die zentrale Recheneinheit des Flugcontrollers dar, auf der der Hauptprozessor (STM32H753) sowie die PX4-Firmware betrieben werden. Das Baseboard stellt vor allem die Schnittstellen zu Sensoren, anderen Komponenten und der Stromversorgung bereit.

FMUv6X-Modul

Baseboard V2A



Abbildung 2.3: Komponenten des Pixhawk 6X: FMU-Modul und Baseboard V2A [3]

2.6.1 Sensorik

Der Pixhawk 6X verfügt über eine dreifach redundante IMU sowie zwei redundante Barometer, die auf getrennten Bussen mit unabhängiger Stromversorgung betrieben werden. Diese Redundanz erhöht die Zuverlässigkeit: Erkennt der PX4 den Ausfall eines Sensors, schaltet das System auf einen funktionierenden Sensor um, um die Flugsteuerung aufrechtzuerhalten.[18] Die Sensoren sind, wie in Abschnitt ?? beschrieben, mit einer Messunsicherheit behaftet, weshalb die redundante Auslegung und die anschließende Sensorfusion im EKF erfolgen.

Die in der eingesetzten Revision verbauten Sensoren sind in Tabelle ?? aufgeführt.

Sensortyp	Bauteil
Beschleunigung/Gyroskop	ICM-20649 / BMI088
Beschleunigung/Gyroskop	ICM-42688-P
Beschleunigung/Gyroskop	ICM-42670-P
Barometer	2× BMP388
Magnetometer	BMM150

Tabelle 2.1: Sensorbestückung des Pixhawk 6X [18]

Zusätzlich sind die IMUs vibrationsisoliert gelagert und werden über Heizwiderstände auf einer konstanten Betriebstemperatur gehalten, um temperaturbedingte Messabweichungen zu reduzieren.[18] Ein Magnetometer ist zwar verbaut, wird in dieser Arbeit jedoch nicht zur Lagebestimmung verwendet (siehe Abschnitt 2.6.3).

2.6.2 Schnittstellen

Der Flugcontroller stellt über das Baseboard eine Vielzahl von Schnittstellen zur Anbindung externer Komponenten bereit. Für diese Arbeit sind insbesondere die folgenden Schnittstellen relevant:

Die serielle Schnittstelle (UART) der Telemetrie-Ports dient der Kommunikation zwischen dem Flugcontroller und dem Jetson Orin NX, über welche die extern berechnete Positionsschätzung an

den EKF übermittelt wird. Die genaue Anbindung wird in Kapitel ?? beschrieben. Über den USB-Anschluss erfolgt die Parametrierung und Kalibrierung des Flugcontrollers mittels der Bodenstationssoftware QGroundControl. Die PWM-Ausgänge des Baseboards steuern die Elektromotoren des UAV an. Darüber hinaus stehen weitere Schnittstellen wie CAN, I²C und SPI zur Anbindung zusätzlicher Sensoren und Peripherie zur Verfügung, die in dieser Arbeit jedoch nicht verwendet werden.[18]

2.6.3 EKF2 – Zustandsschätzung und Sensorfusion

Die Zustandsschätzung des PX4 erfolgt über den Extended Kalman Filter 2 (EKF2), dieser ist in 2.5 beschriebenen EKF. Der EKF2 fusioniert die Messungen der bordeigenen Sensoren mit optionalen externen Referenzen, um Lage, Geschwindigkeit und Position des UAV zu schätzen. Der Zustandsvektor des EKF2 umfasst 24 Zustände, darunter die Lage als Quaternion, Geschwindigkeit, Position, die Bias-Werte von Gyroskop und Beschleunigungssensor, das Erdmagnetfeld, den Magnetometer-Bias sowie die horizontale Windgeschwindigkeit.[19] Da in dieser Arbeit kein GPS zur Verfügung steht, wird die Position des UAV über eine externe visuelle Positionsschätzung bereitgestellt. Diese wird als externe Referenz in den EKF2 eingespeist und ersetzt dort die Funktion, die andernfalls vom GPS übernommen würde. Das Verhalten des EKF2 lässt sich über eine Reihe von Parametern konfigurieren, welche unter anderem festlegen, welche Sensorquellen zur Positions- und Höhenbestimmung herangezogen werden. Die konkrete Parametrierung für den GPS-freien Betrieb mit externer Positionsreferenz wird in Kapitel ?? erläutert.

2.6.4 Betriebssystem

Der Pixhawk 6X betreibt auf dem Hauptprozessor STM32H753 das Echtzeitbetriebssystem NuttX, auf dem die PX4-Firmware ausgeführt wird. NuttX ist ein Echtzeitbetriebssystem, das sicherstellt, dass zeitkritische Steuerungsaufgaben innerhalb garantierter Zeitschranken ausgeführt werden. [20]

Die Kommunikation mit externen Systemen in dieser Arbeit erfolgt über das MAVLink-Protokoll. MAVLink ist ein leichtgewichtiges Nachrichtenprotokoll, das speziell für die Kommunikation zwischen Flugcontrollern und Bodenstationen bzw. Companion-Computern entwickelt wurde. Es serialisiert Telemetriedaten, Steuerbefehle und Sensorwerte in kompakte Binärpakete, die über serielle Schnittstellen oder User Datagram Protocol (UDP) übertragen werden. [21], [22]

Zur Analyse des Flugverhaltens erzeugt der PX4 während des Betriebs ULog-Dateien, die auf der internen SD-Karte gespeichert werden. Diese Log-Dateien enthalten zeitgestempelte Aufzeichnungen aller relevanten Zustandsgrößen, Sensorwerte und EKF2-internen Größen und ermöglichen eine detaillierte Nachanalyse des Systemverhaltens nach dem Flug. [23], [24]

2.6.5 Robot Operating System 2 (ROS2)

ROS2 ist ein Open-Source-Framework für die Entwicklung von Robotersoftware. Es stellt eine einheitliche Middleware bereit, über die verteilte Software-Komponenten – sogenannte *Nodes* – miteinander kommunizieren können. wodurch kein zentraler Master-Prozess mehr benötigt wird und eine höhere Robustheit sowie Echtzeitfähigkeit erreicht werden. In dieser Arbeit wird ROS2 Humble sowie ROS2 Jazzy eingesetzt.[25]

2.6.5.1 Nodes und Topics

Die grundlegende Kommunikationseinheit in ROS2 ist der *Node*: ein eigenständiger Prozess, der eine spezifische Aufgabe übernimmt, beispielsweise die Kamerabildverarbeitung. Nodes tauschen Daten über *Topics* nach dem Publish-Subscribe-Prinzip aus. Ein Node, der Daten erzeugt, veröffentlicht diese als *Publisher* auf einem Topic; ein oder mehrere *Subscriber*-Nodes empfangen die Nachrichten asynchron. Topics sind typisiert, das heißt jedes Topic überträgt Nachrichten eines fest definierten Nachrichtentyps, beispielsweise `geometry_msgs/PoseStamped` für Positionsdaten oder `sensor_msgs/Image` für Kamerabilder. [26], [27]

2.6.5.2 Bag-Dateien

ROS2 ermöglicht die Aufzeichnung von Topic-Daten in sogenannten *Bag-Dateien* mittels des Werkzeugs `rosbag2`. Aufgezeichnete Bags können anschließend offline wiedergegeben werden, sodass das Systemverhalten ohne erneuten Flug reproduzierbar analysiert werden kann. [28]

2.6.5.3 TF2 – Koordinatentransformationen

Das `tf2`-Paket verwaltet in ROS2 einen baumförmigen Graphen von Koordinatentransformationen zwischen den im System definierten Referenzrahmen. **ROS2Humble** Jede Transformation beschreibt die räumliche Beziehung zwischen zwei Frames als homogene Transformation bestehend aus Translation und Rotation. Der TF-Baum wird kontinuierlich über die Topics `/tf` und `/tf_static` aktualisiert, wobei statische Transformationen – beispielsweise die feste Lage einer Kamera relativ zum UAV-Körper – über `/tf_static` einmalig veröffentlicht werden. Jeder Node kann zu jedem Zeitpunkt die Transformation zwischen zwei beliebigen Frames abfragen, sofern ein zusammenhängender Pfad im TF-Baum existiert.

3 Stand der Technik

Dieses Kapitel gibt einen Überblick über den aktuellen Stand der Technik im Bereich der Global Navigation Satellite System (GNSS)-freien Lokalisierung von UAV und ordnet die in dieser Arbeit gewählten Methoden in den wissenschaftlichen Kontext ein. Zunächst werden bestehende Lokalisierungsansätze ohne GNSS vorgestellt und hinsichtlich ihrer Eignung für Innenraumanwendungen bewertet. Anschließend werden verschiedene Fiducial-Marker-Systeme verglichen und deren Eigenschaften im Hinblick auf die Anforderungen dieser Arbeit diskutiert. Abschließend wird auf die simultane Lokalisierung und Kartierung eingegangen, die die Grundlage für die in dieser Arbeit verwendete Kartierungsmethodik bildet.

3.1 GNSS-freie Lokalisierung von UAVs

Die Navigation ohne GNSS stellt in der Luftfahrt eine erhebliche Herausforderung dar, da GNSS als primäre Quelle absoluter Positionsinformationen dient. In dessen Abwesenheit muss die Position aus der Integration fehlerbehafteter Inertialmessungen geschätzt werden, was, wie in Abschnitt ?? beschrieben, zu einem zeitlich anwachsenden Positionsfehler führt. Daher ist es notwendig, diesen Fehler durch absolute oder relative Lokalisierungsmethoden auszugleichen.[29]

3.1.1 Absolute Lokalisierung

Absolute Lokalisierungsverfahren spielen eine wichtige Rolle, wenn die genaue Position eines UAV bezogen auf einen globalen Referenzrahmen bekannt sein muss.[29] Die gängigste Methode zur Umsetzung einer absoluten Lokalisierung ist ein satellitengestütztes System wie GPS oder Galileo. Da in der für diese Arbeit relevanten Flugumgebung kein ausreichender Satellitenempfang herrscht, finden diese Systeme keine Anwendung. Eine weitere Möglichkeit der absoluten Lokalisierung bieten Template- und Feature-basierte Verfahren sowie Semantic Mapping.

Bei Template- beziehungsweise Feature-basierten Verfahren werden Aufnahmen des UAV mit bekannten Referenzbildern oder gespeicherten Merkmalen verglichen. Diese Systeme berücksichtigen ausschließlich visuelle Merkmale, ohne semantische Beziehungen einzubeziehen.[29] Ein verwandtes Konzept stellen Fiducial-Marker dar, bei denen anstelle natürlicher Bildmerkmale künstlich erzeugte, eindeutig kodierte Muster als Referenz dienen. Durch ihre definierte Geometrie und Kodierung ermöglichen sie eine präzisere und robustere Posenschätzung als natürliche Bildmerkmale, weshalb sie in dieser Arbeit als Grundlage der Lokalisierung eingesetzt werden. Im Sinne einer globalen absoluten Lokalisierung im Weltkoordinatensystem sind Template- und Feature-basierte Verfahren für Innenraumanwendungen jedoch wenig geeignet, da geeignete Referenzdaten schwer zu erfassen sind.[29]

Semantic Mapping verfolgt einen ähnlichen Ansatz: Auch hier werden zunächst Referenzdaten erstellt, die anschließend mit aktuell erfassten Daten abgeglichen werden. Der Unterschied liegt darin, dass nicht nur visuelle Merkmale, sondern auch semantische Beziehungen berücksichtigt werden, so wird beispielsweise ein Tisch als Tisch und eine Treppe als Treppe interpretiert.[29] Dieses Verfahren findet in der vorliegenden Arbeit keine Anwendung, da die Erkennungsleistung stark von der Stabilität der jeweiligen Umgebung abhängig ist.

Da die einzige praktikabel umsetzbare Methode der absoluten Lokalisierung ein satellitengestütztes System darstellt, welches wie bereits erwähnt in der vorliegenden Umgebung nicht verfügbar ist, wird in dieser Arbeit auf absolute Lokalisierungsverfahren verzichtet und ausschließlich relative Lokalisierungsmethoden betrachtet. Die grundlegende Methodik der zuvor vorgestellten Verfahren findet dabei ebenfalls Anwendung, jedoch ohne Bezug zu einem globalen Referenzrahmen.

3.1.2 Relative Lokalisierung

Die relative Lokalisierung zielt darauf ab, die Position und Orientierung eines UAV innerhalb eines lokalen Koordinatensystems zu bestimmen. Die Position wird dabei bezogen auf einen definierten Referenzpunkt ermittelt. Im Folgenden werden die gängigsten Methoden vorgestellt und hinsichtlich ihrer Eignung für die vorliegende Innenraumanwendung bewertet.

3.1.2.1 Dead Reckoning Localization

Bei der Dead Reckoning Localization (DRL) handelt es sich um ein Verfahren, bei dem die aktuelle Position eines Objekts ausgehend von einem letzten bekannten Startpunkt kontinuierlich berechnet wird.[30] Die Berechnung erfolgt auf Basis der bereitgestellten IMU-Daten durch Integration dieser. Wie in Abschnitt 2.4 bereits beschrieben, wirken auf die Sensoren erhebliche Fehler, sodass die direkte Integration der rohen IMU-Messdaten zu großen Translationsfehlern führt. Aus diesem Grund ist eine Filterung der Eingangsdaten notwendig. Am weitesten verbreitet sind hierbei verschiedene Abwandlungen des Kalman-Filters.

Experimentelle Untersuchungen mit dem PX4-Autopiloten und einem handelsüblichen Pixhawk-Flugregler zeigen, dass der EKF2 bereits nach 7 Sekunden eine Geschwindigkeitsabweichung von $\sigma_{vel} \approx 0,024 \text{ m/s}$ aufweist, was zu einem zunehmenden Positionsfehler im Dezimeterbereich führt.[31] Verschiedene Arbeiten zeigen, dass sich der Drift vor allem durch Nutzung verbesserter Algorithmen wie dem Invariant Extended Kalman Filter (IEKF) minimieren, jedoch nicht vollständig vermeiden lässt.[30][31][19] Da im verwendeten Flugcontroller, wie in Kapitel 2.6 beschrieben, der EKF implementiert ist, wird nicht weiter auf andere Abwandlungen des Algorithmus eingegangen.

Grundsätzlich ist DRL für den Innenraum nur zeitlich begrenzt geeignet und als primäre Positionsquelle nicht ausreichend. Im Normalfall wird DRL daher als Fallback-Strategie genutzt, wenn die primäre Positionsquelle nicht verfügbar ist.[31] In dieser Arbeit wird der Flugcontroller entsprechend konfiguriert.

3.1.2.2 Visuelle Odometrie und optischer Fluss

Visuelle Odometrie sowie optischer Fluss sind grundlegende Verfahren zur Lokalisierung eines UAV. Die Visuelle Odometrie (VO) schätzt die Bewegung einer Kamera anhand sequenzieller Bilddaten, ohne eine Karte der Umgebung zu erstellen. Dabei werden markante Bildpunkte, auch Landmarken genannt, zwischen aufeinanderfolgenden Frames verfolgt und aus deren Verschiebung auf die Kamerabewegung geschlossen.[29]

Darüber hinaus existieren Visuelle Inertial Odometrie (VIO)-Ansätze, die die Robustheit der VO durch Einbeziehen von IMU-Informationen verbessern.[32] Die visuellen Daten können dabei den Drift der IMU reduzieren, während die IMU-Daten den metrischen Maßstab sowie Roll- und Nickwinkel

aus den visuellen Daten wiederherstellen können.[32] Es gibt sowohl mono- als auch stereokamerabasierte Ansätze, wobei Stereokameras aufgrund der direkten Tiefenschätzung eine höhere Genauigkeit erzielen.[32] Die Fusion von IMU und VO zu VIO erfolgt typischerweise über einen EKF.[32]

Da VO und VIO keinen absoluten Positionsbezug besitzen, akkumulieren diese Verfahren über die Zeit einen Drift und sind damit nur bedingt für eine langfristig stabile Innenraumlokalisierung geeignet.[29] Zudem ist die Leistung kamerabasierter Verfahren stark von den Lichtverhältnissen der Umgebung abhängig.[32] Weiterhin visuelle Odometrie setzt strukturierte Umgebungen voraus, welche in der Versuchsumgebung nicht ohne weiteres gegeben sind.

Der optische Fluss stellt ein verwandtes Verfahren dar, das im Gegensatz zur VO lediglich zweidimensionale Geschwindigkeitsinformationen liefert.[29] Aus diesem Grund ist der optische Flow nicht zur Positionserkennung einer UAV geeignet.

3.1.3 Simultane Lokalisierung und Kartierung

Simultaneous Localization and Mapping (SLAM) beschreibt eine Problemstellung an der Schnittstelle von Computer Vision und Robotik. Dabei geht es um die selbstständige Erstellung einer Karte einer unbekannten Umgebung bei gleichzeitiger Bestimmung der eigenen Position innerhalb dieser Umgebung.[33] Der Begriff simultan beschreibt genau diesen Zusammenhang: Kartierung und Positionsbestimmung müssen parallel erfolgen, da jede Aufgabe die andere voraussetzt.[33] Die Lösung dieses Problems erfolgt üblicherweise durch filterbasierte Methoden, wie den EKF, oder durch optimierungsbasierte Methoden, die im Folgenden näher beschrieben werden.[33]

Filterbasierte SLAM Algorithmen verarbeiten Messungen sequenziell und lassen keine Korrektur von vergangenen Messungen zu. Insbesondere fehlt filterbasierten Methoden die Fähigkeit zur globalen Kartenkorrektur durch Loop Closure, was zu einer geringeren Kartierungsgenauigkeit im Vergleich zu optimierungsbasierten Methoden führt. In der Lokalisierung sind filterbasierte Methoden aufgrund ihrer geringeren Rechenkomplexität jedoch schneller.[33] Der aktuelle Standard bei SLAM-Algorithmen sind optimierungsbasierte Methoden.

3.1.3.1 Phasen optimierungsbasierter SLAM Methoden

Der allgemeine optimierungsbasierte SLAM-Prozess lässt sich in folgende Phasen unterteilen:

Feature Extraction bezeichnet die Extraktion markanter Merkmale aus den Sensordaten, die als Grundlage für die spätere Zuordnung dienen.[33]

Feature Matching beschreibt den Abgleich extrahierter Merkmale zwischen aufeinanderfolgenden Frames, um die Bewegung des Systems zu schätzen.[33] Beispiele dieser Methoden werden in Abschnitt 3.1.2 beschrieben.

Map Initialization bezeichnet die Initialisierung der Karte zu Beginn des SLAM-Prozesses. Dabei werden zunächst markante Bildmerkmale aus den ersten Frames extrahiert und einander zugeordnet, um die initiale Struktur der Umgebung zu schätzen. Aus diesen Zuordnungen werden erste Kartenpunkte sowie deren räumliche Positionen im dreidimensionalen Raum bestimmt. Die Map Initialization bildet die Grundlage, auf der alle weiteren Kartenpunkte und Posenschätzungen aufgebaut werden. `vslam_core_modules_2024`

Loop Closure bezeichnet die Erkennung bereits besuchter Orte. Wird ein solcher Ort erkannt,

wird die akkumulierte Abweichung anhand gespeicherter Merkmale berechnet und als zusätzlicher Constraint den Faktorgraphen eingetragen. Die anschließende globale Optimierung verbessert die Konsistenz der gesamten Karte erheblich. [33] Der schematische Ablauf von Loop Closure ist in Abbildung 3.1 dargestellt. Die Funktion des Faktorgraphen wird in Abschnitt 3.1.3.2 näher beschrieben.




Abbildung 3.1: Veranschaulichung des Loop-Closure-Effekts: (a) Reale Trajektorie ohne akkumulierten Fehler. (b) Geschätzte Trajektorie mit akkumuliertem Drift ohne Loop Closure. (c) Korrigierte Trajektorie nach Anwendung von Loop Closure mit reduziertem akkumuliertem Drift. vgl. [34]

3.1.3.2 Faktorgraph

Im folgenden Abschnitt wird der Faktorgraph nur schematisch erläutert, um ein grundsätzliches Verständnis dieser Methodik zu erlangen. Genaue Herleitungen sowie die Mathematik hinter dem Prinzip können den Quellen [35], [36] und [37] entnommen werden.

Ein Faktorgraph ist eine grafische Darstellung eines Schätzproblems und besteht aus zwei Arten von Knoten: Variablenknoten und Faktorknoten.[35] Die Variablenknoten sind die unbekannten Größen, die geschätzt werden sollen – bei SLAM die Pose des UAV und die Position der Landmarken.[35] Die Faktorknoten verbinden diese Variablen und repräsentieren die Messungen oder das Vorwissen.[35]

Der Faktorgraph in Abbildung 3.2 zeigt die grundlegende Struktur eines SLAM-Problems. Hierbei ist der Faktorgraph stark vereinfacht; auf mathematische Beziehungen wird verzichtet. Die blauen Kreise repräsentieren die Variablenknoten der UAV-Posen x_1 bis x_4 , also die gesuchten Positionen und Orientierungen des UAV zu aufeinanderfolgenden Zeitpunkten. Die grünen Kreise t_1 bis t_3 stellen die Landmarken dar, deren Positionen im Weltkoordinatensystem ebenfalls als Variablenknoten geschätzt werden.

Es werden zwei Arten von Faktorknoten (Constraints) unterschieden: Die violetten Quadrate repräsentieren Odometrie-Constraints, die jeweils zwei aufeinanderfolgende Posen verbinden und die relative Bewegung zwischen diesen beschreiben. Die orangen Quadrate sind Messungs-Constraints

und verbinden eine UAV-Pose mit einer Landmarke – sie repräsentieren die Beobachtung, dass Tag t_i von Pose x_j aus detektiert wurde.

Wird die Pose x_4 als bereits bekannter Ort – identisch mit x_1 – wiedererkannt, entsteht ein Loop-Closure-Constraint, der x_1 und x_4 im Faktorgraphen verbindet, wie durch den roten Pfeil in Abbildung 3.2 dargestellt. Dieser zusätzliche Constraint schließt die Schleife und ermöglicht dem Optimierer, den über die Trajektorie akkumulierten Drift rückwirkend über alle Posen zu korrigieren.[38]




Abbildung 3.2: Vereinfachter Faktorgraph eines SLAM-Problems, vgl. [35], [36], [37]

Das Ziel der Optimierung ist die Maximum-a-posteriori-Schätzung – also die Konfiguration aller Variablen (Posen und Landmarken) zu finden, die die Gesamtwahrscheinlichkeit aller Beobachtungen maximiert. Äquivalent dazu wird der Gesamtfehler über alle Constraints minimiert.[39] Bildlich bedeutet das, dass der Optimierer die Variablen solange “verschiebt”, bis der Gesamtfehler über allen Messungen minimal ist. Bekannte Faktorgraph Bibliotheken sind Georgia Tech Smoothing and Mapping (GTSAM) und General Graph Optimization (g2o).

3.1.3.3 SLAM-Varianten

Kamerabasierte Visual SLAM (vSLAM) nutzt visuelle Sensordaten, um gleichzeitig die Pose eines Roboters zu schätzen und eine Karte der Umgebung zu erstellen.[33] Es baut auf den Konzepten der VO und VIO auf und erweitert diese um die Fähigkeit zur globalen Kartenkonsistenz durch Loop Closure.[37] Durch die Erkennung bereits besuchter Orte kann das System akkumulierte Posenfehler korrigieren und eine global konsistente Karte aufbauen. **ORB-SLAM** ist ein weit verbreitetes Open-Source-SLAM-System, das ORB-Merkmale zur Merkmalerkennung verwendet und Mono-, Stereo-, RGB-D- sowie visuell-inertiale Kamerakonfigurationen unterstützt.[33]

Kamerabasiertes vSLAM nutzt visuelle Sensordaten, um gleichzeitig die Pose eines Roboters zu schätzen und eine Karte der Umgebung zu erstellen.[33] Es baut auf den Konzepten der VO und VIO auf und erweitert diese um die Fähigkeit zur globalen Kartenkonsistenz durch Loop Closure.[37] Durch die Erkennung bereits besuchter Orte kann das System akkumulierte Posenfehler korrigieren und eine global konsistente Karte aufbauen. Ein weit verbreitetes Beispiel ist **orb-slam3**, ein Open-Source-System, das ORB-Merkmale zur Merkmalerkennung verwendet.[33] Je nach Konfiguration unterstützt es Mono-, Stereo- und RGB-D-Kameras als reines vSLAM sowie die Kombination mit

einer IMU als visuell-inertialen SLAM.

TagSLAM ist eine Spezialisierung von vSLAM für Fiducial-Marker. Anstelle natürlicher Bildmerkmale werden AprilTag-Marker als definierte Referenzpunkte verwendet. Da die Geometrie der Marker bekannt ist, entfällt die aufwendige Merkmalsbeschreibung und das Matching; stattdessen liefert jede Markerdetektion eine direkte Posenmessung relativ zur Kamera. TagSLAM nutzt den GTSAM zur Faktorgraph Optimierung als Backend und ermöglicht neben vollständigem SLAM Posenschätzung.[40]

ORB-SLAM ist ein weit verbreitetes Open-Source-SLAM-System, das ORB-Merkmale zur Merkmalerkennung verwendet und Mono-, Stereo-, RGB-D- sowie visuell-inertiale Kamerakonfigurationen unterstützt.[33]

Light Detection and Ranging (LiDAR)-SLAM verwendet einen Laserscanner anstelle einer Kamera als primären Sensor [41]. Ein LiDAR misst Entfernungen durch Laufzeitmessung ausgesendeter Laserpulse und erzeugt dabei eine dichte Punktwolke der Umgebung. Da die Tiefenmessung direkt und metrikgenau erfolgt, ist LiDAR-SLAM im Vergleich zu monokularem vSLAM nicht auf eine Skaleninitialisierung angewiesen und liefert in der Regel robustere Ergebnisse unter wechselnden Lichtverhältnissen [41]. Gegenüber kamerabasierten Verfahren sind LiDAR-Systeme jedoch deutlich teurer, schwerer und energieintensiver, was ihren Einsatz auf kleinen UAVs einschränkt.

3.2 Fiducial-Marker-Systeme

Im Folgenden wird ein Überblick über die am weitesten verbreiteten Fiducial-Marker-Systeme gegeben. Fiducial-Systeme wurden entwickelt, um in wenig strukturierten Umgebungen eine visuelle Lokalisierung gewährleisten zu können. Fiducial-Marker stellen ein gut unterscheidbares Muster mit starken visuellen Eigenschaften dar. Sie verfügen in den meisten Fällen auch über eine spezifische Kodierung als Sicherheitsmechanismus gegen Fehlerkennung.[42] Im Folgenden werden die in Abbildung 3.3 dargestellten gängigen Fiducial-Marker vorgestellt.




Abbildung 3.3: Übersicht gängiger Fiducial-Marker: a) ARTag; b) AprilTag; c) Aruco d) Stag [43], [44]

3.2.0.1 ARTag

ARTag wurde 2005 von Mark Fiala als Weiterentwicklung von ARToolKit vorgestellt.[45] Es verwendet digitale Kodierungsverfahren, wodurch ARTag im Vergleich zu früheren Systemen niedrigere und quantifizierbare Fehlerraten aufweist.[45] Ein ARTag besteht aus einem quadratischen Rand, der ein binäres Raster aus schwarzen und weißen Zellen umschließt, welches eine eindeutige ID kodiert.[45]

Es lassen sich 2048 unterschiedliche IDs erzeugen, wobei 10 Bits für die Marker-ID und 26 Bits zur Redundanz genutzt werden.[45] ARTag verwendet keine einheitliche minimale Hammingdistanz zwischen den Codewörtern.[45] Aus einer Aufnahme des Markers lässt sich eine 6D-Pose bestimmen.[45] ARTag ist das einzige System, welches nicht vollständig Open-Source ist.

3.2.0.2 AprilTag

AprilTag wurde 2011 von Edwin Olson an der University of Michigan vorgestellt.[46] AprilTag stellt eine schnellere und robustere Neuimplementierung des ARTag-Ansatzes dar.[46] Ein AprilTag besteht aus einem schwarzen quadratischen Rand, der ein binäres Raster aus schwarzen und weißen Zellen umschließt, welches eine eindeutige ID kodiert.[46] Das System ermöglicht die vollständige Bestimmung der sechs Freiheitsgrade der Pose aus einem einzelnen Bild und ist robust gegenüber Verdeckung, Verzerrung und Linsenverzeichnung.[46] Marker sind in verschiedene Familien unterteilt; das Namensschema TagNNhM beschreibt dabei NN als die Gesamtzahl der Datenbits und hM als die minimale Hammingdistanz.[46] Die Familie tag36h11 verwendet ein 6×6 -Raster mit einer minimalen Hammingdistanz von 11, die Familie tag16h5 ein 4×4 -Raster mit einer minimalen Hammingdistanz von 5.[46] tag16h5 lässt sich aufgrund der größeren Pixelgröße prinzipiell aus größerer Entfernung erkennen, jedoch mit höherer Unsicherheit.[46] In dieser Arbeit wird die Familie tag36h11 verwendet.[46] Mit AprilTag 2 wurde 2016 eine vollständig überarbeitete Detektion vorgestellt, die höhere Detektionsraten bei geringerem Rechenaufwand erreicht.[47]

3.2.0.3 ArUco

ArUco wurde 2014 von Garrido-Jurado et al. vorgestellt.[48] Ein ArUco-Marker ist ähnlich wie ARTag und AprilTag aufgebaut. Er ist ebenfalls quadratisch und besitzt einen breiten Rand, in dessen Innerem sich eine Binärmatrix befindet, welche die Identifikationsnummer des Markers bestimmt.[48] Das System bietet einen Algorithmus zur automatischen Generierung konfigurierbarer Marker.[48] ArUco-Marker sind ebenfalls in Familien eingeteilt; das Namensschema $\text{DICT_N} \times \text{N_M}$ beschreibt dabei $\text{N} \times \text{N}$ als die Rastergröße der Datenbits und M als die maximale Anzahl der Marker im Dictionary.[48] Je kleiner das Dictionary, desto höher die Hammingdistanz zwischen den Markern.[48] ArUco ist in die Bibliothek OpenCV integriert.[48]

3.2.0.4 STag

STag wurde 2019 von Benligiray et al. vorgestellt.[49] Im Gegensatz zu den rein quadratischen Systemen verwendet STag eine kreisförmige Randstruktur, die eine stabilere Posenschätzung ermöglicht.[49] Auch STags lassen sich in Familien unterteilen. So gibt es beispielsweise STag HD11, HD13 oder HD23, wobei HD für Hammingdistanz steht.[49] Je höher die Hammingdistanz, desto kleiner ist die Anzahl an möglichen Tags.[49]

3.2.0.5 Detektion

Alle vorgestellten Fiducial-Marker-Systeme stellen Bibliotheken zur Detektion bereit. Die Detektion eines Fiducial-Markers gliedert sich in zwei Hauptkomponenten: den eigentlichen Detektor, der die Position möglicher Marker im Bild schätzt, und das Kodierungssystem, das die ausgelesene ID auf

Gültigkeit prüft.[46] Im Folgenden wird der Ablauf am Beispiel von AprilTag beschrieben.

Der Detektor sucht im Bild nach viereckigen, dunklen Flächen mit hellem Rand — den sogenannten Quads.[46] Dazu analysiert er, wo im Bild starke Helligkeitsübergänge auftreten, und fasst Bereiche mit ähnlichen Übergängen zu geraden Linien zusammen.[46] Da das Verfahren auf diesen Helligkeitsunterschieden basiert, funktioniert es auch bei wechselnden Lichtverhältnissen zuverlässig.[46]

Aus je vier passenden Linien wird ein Quad gebildet; kleine Lücken oder Verdeckungen werden dabei toleriert.[46] Die genauen Eckpunkte des Quads ergeben sich aus den Schnittpunkten der Linien.[46]

Für jeden gefundenen Quad wird anschließend berechnet, wie das Bild des Markers entzerrt werden muss, um ihn frontal und unverzerrt darzustellen.[46] Aus dieser Entzerrung lassen sich zusammen mit der Brennweite der Kamera und der bekannten physischen Markergröße Position und Orientierung des Markers im Raum ableiten.[46] Abschließend werden die Datenbits des Markers ausgelesen und gegen das bekannte Dictionary geprüft – erst dieser Schritt bestätigt, dass es sich tatsächlich um einen gültigen Marker handelt, und reduziert Falschdetektionen.[46]

4 Systembeschreibung

In diesem Kapitel wird die Testumgebung beschrieben, sowie auf die Softwarearchitekturen eingegangen. Außerdem wird die Systempipeline erläutert, die zur Entwicklung der Echtzeiterkennung verwendet wurde. Es werden die verschiedenen Konzepte vorgestellt, die zur Auswahl eines Echtzeitmodells geführt haben.

4.1 Aufbau der Testumgebung

4.2 Softwarearchitektur

4.3 Systempipeline

4.3.1 elektrischer Aufbau der Holybro X650 mit Pixhawk 6X

5 Implementierung der Kartierung

5.1 Datensatz- und Objektauswahl

5.2 Training der Modelle

5.2.1 Yolov8 Training

6 Ansteuerung des KUKA iiwa 7 R800

6.1 Kommunikationsschnittstellen

6.2 Greifpunktberechnung

6.2.1 Vortrainiertes Modell Dexnet

6.2.2 Segmentierung mithilfe der Bounding Boxen und dbscan

6.2.3 Segmentierungslogik je Objekt

7 Systemintegration

8 Evaluation des Greifens

8.1 Erfolgskriterien - Erfolgsquote und Fehlerrate

8.2 Erkennungsgenauigkeit

8.3 Positioniergenauigkeit

8.4 Zeitliche Performance und Echtzeitfähigkeit

9 Zusammenfassung und Ausblick

Literatur

- [1] H. Studiawan und K.-K. R. Choo, *Drone and UAV Forensics: A Hands-On Approach*. Springer Nature Switzerland, 2026, ISBN: 9783031935114. DOI: 10.1007/978-3-031-93511-4.
- [2] Y.-T. Wu, Z. Qin, A. Eizad und S.-K. Lyu, "Numerical investigation of the mechanical component design of a hexacopter drone for real-time fine dust monitoring", *Journal of Mechanical Science and Technology*, Jg. 35, Nr. 7, S. 3101–3111, 2021, ISSN: 1976-3824. DOI: 10.1007/s12206-021-0632-y.
- [3] P. Modellbau, *Holybro X650*, <https://www.premium-modellbau.de/holybro-holybro-x650-development-kit-pixhawk-6c-m10-gps-433-mhz-30180>, Zugriff am 30.05.2026, 2026.
- [4] ISO, "Road Vehicles – Vehicle Dynamics and Road-Holding Ability – Vocabulary", International Organization for Standardization, Geneva, Switzerland, Standard ISO 8855:2011, 2011.
- [5] ISO, "Robots and Robotic Devices – Coordinate Systems and Motion Nomenclatures", International Organization for Standardization, Geneva, Switzerland, Standard ISO 9787:2013, Mai 2013.
- [6] PX4 Development Team, *Using Vision or Motion Capture Systems for Position Estimation*, https://docs.px4.io/main/en/ros/external_position_estimation, Zugriff am 31.05.2026, 2024.
- [7] R. Szeliski, *Computer Vision: Algorithms and Applications*. Springer International Publishing, 2022, ISBN: 9783030343729. DOI: 10.1007/978-3-030-34372-9.
- [8] B. Siciliano, L. Sciavicco, L. Villani und G. Oriolo, *Robotics*. Springer London, 2009, ISBN: 9781846286421. DOI: 10.1007/978-1-84628-642-1.
- [9] *Springer Handbook of Robotics*. Springer International Publishing, 2016, ISBN: 9783319325521. DOI: 10.1007/978-3-319-32552-1.
- [10] Q. Quan, *Introduction to Multicopter Design and Control*. Springer Singapore, 2017, ISBN: 9789811033827. DOI: 10.1007/978-981-10-3382-7.
- [11] G. Bradski und A. Kaehler, *Learning OpenCV: Computer Vision with the OpenCV Library*. O'Reilly Media, 2008, ISBN: 978-0596516130. Adresse: <https://learning.oreilly.com/library/view/learning-opencv/9780596516130/ch11s05.html>.
- [12] J. S. Dai, "Euler–Rodrigues formula variations, quaternion conjugation and intrinsic connections", *Mechanism and Machine Theory*, Jg. 92, S. 144–152, 2015, ISSN: 0094-114X. DOI: <https://doi.org/10.1016/j.mechmachtheory.2015.03.004>. Adresse: <https://www.sciencedirect.com/science/article/pii/S0094114X15000415>.
- [13] V. Capuano, L. Xu und J. Estrada Benavides, "Smartphone MEMS Accelerometer and Gyroscope Measurement Errors: Laboratory Testing and Analysis of the Effects on Positioning Performance", *Sensors*, Jg. 23, Nr. 17, S. 7609, 2023, ISSN: 1424-8220. DOI: 10.3390/s23177609.

- [14] C. Chen und X. Pan, "Deep Learning for Inertial Positioning: A Survey", *IEEE Transactions on Intelligent Transportation Systems*, 2024. DOI: 10.1109/TITS.2024.3381161. arXiv: 2303.03757 [cs.RO].
- [15] R. E. Kalman, "A New Approach to Linear Filtering and Prediction Problems", *Transactions of the ASME – Journal of Basic Engineering*, Jg. 82, Nr. 1, S. 35–45, 1960. DOI: 10.1115/1.3662552.
- [16] Y. Kim und H. Bang, "Introduction to Kalman Filter and Its Applications", in *Introduction and Implementations of the Kalman Filter*, F. Govaers, Hrsg., London: IntechOpen, 2018, Kap. 2. DOI: 10.5772/intechopen.80600. Adresse: <https://doi.org/10.5772/intechopen.80600>.
- [17] J. A. Mendoza-Mendoza, V. J. Gonzalez-Villela, G. Sepulveda-Cervantes, M. Mendez-Martinez und H. Sossa-Azuela, *Advanced Robotic Vehicles Programming: An Ardupilot and Pixhawk Approach*. Apress, 2020, ISBN: 9781484255315. DOI: 10.1007/978-1-4842-5531-5.
- [18] PX4 Development Team, *Holybro Pixhawk 6X*, https://docs.px4.io/v1.16/en/flight_controller/pixhawk6x, Abgerufen am 04.06.2026.
- [19] N. Y. Ko, W. Youn, I. H. Choi, G. Song und T. S. Kim, "Features of Invariant Extended Kalman Filter Applied to Unmanned Aerial Vehicle Navigation", *Sensors*, Jg. 18, Nr. 9, S. 2855, Aug. 2018, ISSN: 1424-8220. DOI: 10.3390/s18092855.
- [20] PX4 Development Team, *PX4 Architectural Overview*, <https://docs.px4.io/main/en/concept/architecture.html>, Abgerufen am 07.06.2026, 2025.
- [21] MAVLink Development Team, *MAVLink Developer Guide*, <https://mavlink.io/en/>, Erstveröffentlichung 2009 durch Lorenz Meier; abgerufen am 07.06.2026, 2009.
- [22] PX4 Development Team, *MAVLink Messaging – PX4 Autopilot Documentation*, <https://docs.px4.io/main/en/middleware/mavlink.html>, Abgerufen am 07.06.2026, 2025.
- [23] PX4 Development Team, *ULog File Format – PX4 Autopilot Documentation*, https://docs.px4.io/main/en/dev_log/ulog_file_format.html, Abgerufen am 07.06.2026, 2025.
- [24] PX4 Development Team, *Flight Reporting – PX4 Autopilot Documentation*, https://docs.px4.io/main/en/getting_started/flight_reporting.html, Abgerufen am 07.06.2026, 2025.
- [25] Open Robotics, *ROS 2 Middleware Implementations*, <https://docs.ros.org/en/humble/Concepts/Advanced/About-Middleware-Implementations.html>, ROS 2 Humble Hawksbill; abgerufen am 07.06.2026, 2022.
- [26] Open Robotics, *Nodes – ROS 2 Documentation: Humble*, <https://docs.ros.org/en/humble/Concepts/Basic/About-Nodes.html>, ROS 2 Humble Hawksbill; abgerufen am 07.06.2026, 2022.
- [27] Open Robotics, *Topics – ROS 2 Documentation: Humble*, <https://docs.ros.org/en/humble/Concepts/Basic/About-Topics.html>, ROS 2 Humble Hawksbill; abgerufen am 07.06.2026, 2022.

- [28] Open Robotics, *Recording and Playing Back Data – ROS 2 Documentation: Humble*, <https://docs.ros.org/en/humble/Tutorials/Beginner-CLI-Tools/Recording-And-Playing-Back-Data/Recording-And-Playing-Back-Data.html>, ROS 2 Humble Hawksbill; abgerufen am 07.06.2026, 2022.
- [29] I. Jarraya, A. Al-Batati, M. B. Kadri u. a., “Gnss-denied unmanned aerial vehicle navigation: analyzing computational complexity, sensor fusion, and localization methodologies”, *Satellite Navigation*, Jg. 6, Nr. 1, Apr. 2025, ISSN: 2662-1363. DOI: 10.1186/s43020-025-00162-z.
- [30] H. Zhou, Y. Zhao, X. Xiong, Y. Lou und S. Kamal, “IMU Dead-Reckoning Localization with RNN-IEKF Algorithm”, in *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2022, S. 11 382–11 387. DOI: 10.1109/IROS47612.2022.9982087.
- [31] J. T. Jang, A. Santamaria-Navarro, B. T. Lopez und A.-a. Agha-mohammadi, “Analysis of State Estimation Drift on a MAV Using PX4 Autopilot and MEMS IMU During Dead-reckoning”, in *2020 IEEE Aerospace Conference*, 2020, S. 1–11. DOI: 10.1109/AERO47225.2020.9172736.
- [32] J. Bednář, M. Petrlík, K. C. T. Vivaldini und M. Saska, “Deployment of Reliable Visual Inertial Odometry Approaches for Unmanned Aerial Vehicles in Real-world Environment”, in *2022 International Conference on Unmanned Aircraft Systems (ICUAS)*, 2022, S. 167–176. DOI: 10.1109/ICUAS54217.2022.9836067.
- [33] A. Khole, A. Thakar, S. Shende und V. Karajkhede, “A Comprehensive Study on Simultaneous Localization and Mapping (SLAM): Types, Challenges and Applications”, in *2023 International Conference on Sustainable Computing and Smart Systems (ICSCSS)*, 2023, S. 643–650. DOI: 10.1109/ICSCSS57650.2023.10169695.
- [34] S. Gong, *Loop Closure*, <https://stevengong.co/notes/Loop-Closure>, Abgerufen am 06.06.2026.
- [35] T. Lai, *A Review on Visual-SLAM: Advancements from Geometric Modelling to Learning-based Semantic Scene Understanding*, 2022. DOI: 10.48550/ARXIV.2209.05222.
- [36] F. Dellaert und M. Kaess, “Factor Graphs for Robot Perception”, *Foundations and Trends in Robotics*, Jg. 6, Nr. 1-2, S. 1–139, 2017, ISSN: 1935-8261. DOI: 10.1561/23000000043.
- [37] D. Cai, R. Li, Z. Hu, J. Lu, S. Li und Y. Zhao, “A comprehensive overview of core modules in visual SLAM framework”, *Neurocomputing*, Jg. 590, S. 127 760, 2024, ISSN: 0925-2312. DOI: 10.1016/j.neucom.2024.127760.
- [38] M. Kaess, H. Johannsson, R. Roberts, V. Ila, J. Leonard und F. Dellaert, “iSAM2: Incremental Smoothing and Mapping Using the Bayes Tree”, *International Journal of Robotic Research - IJRR*, Jg. 31, S. 216–235, Mai 2012. DOI: 10.1177/0278364911430419.
- [39] F. Dellaert, “Factor Graphs and GTSAM: A Hands-on Introduction”, Georgia Institute of Technology, Techn. Ber., 2012. Adresse: <https://gtsam.org/tutorials/intro.html>.
- [40] B. Pfrommer und K. Daniilidis, *TagSLAM: Robust SLAM with Fiducial Markers*, 2019. arXiv: 1910.00679 [cs.RO].

- [41] X. Yue, Y. Zhang und M. He, *LiDAR-based SLAM for robotic mapping: state of the art and new frontiers*, 2023. DOI: 10.48550/ARXIV.2311.00276.
- [42] M. Kalaitzakis, B. Cain, S. Carroll, A. Ambrosi, C. Whitehead und N. Vitzilaios, "Fiducial Markers for Pose Estimation: Overview, Applications and Experimental Comparison of the ARTag, AprilTag, ArUco and STag Markers", *Journal of Intelligent and Robotic Systems*, Jg. 101, Nr. 4, März 2021, ISSN: 1573-0409. DOI: 10.1007/s10846-020-01307-9.
- [43] M. Loipfuehrer, "Efficient and Robust Circle Grids for Fiducial Detection", Supervisor: Prof. Dr. Daniel Cremers, Advisor: Nikolaus Demmel, Master's Thesis, Technische Universität München, Mai 2022. Adresse: https://cvg.cit.tum.de/_media/members/demmeln/loipfuehrer2022ma.pdf.
- [44] F. Siri, J. Song und M. Svinin, "Experimental verification of coverage control of multi-agent systems with obstacle avoidance", *The Journal of Engineering*, Jg. 2024, Dez. 2024. DOI: 10.1049/tje2.70045.
- [45] M. Fiala, "ARTag, a fiducial marker system using digital techniques", in *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR 05)*, Bd. 2, 2005, S. 590–596. DOI: 10.1109/CVPR.2005.74.
- [46] E. Olson, "AprilTag: A robust and flexible visual fiducial system", in *2011 IEEE International Conference on Robotics and Automation*, 2011, S. 3400–3407. DOI: 10.1109/ICRA.2011.5979561.
- [47] J. Wang und E. Olson, "AprilTag 2: Efficient and robust fiducial detection", in *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2016, S. 4193–4198. DOI: 10.1109/IROS.2016.7759617.
- [48] S. Garrido-Jurado, R. Muñoz-Salinas, F. Madrid-Cuevas und M. Marín-Jiménez, "Automatic generation and detection of highly reliable fiducial markers under occlusion", *Pattern Recognition*, Jg. 47, Nr. 6, S. 2280–2292, 2014, ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2014.01.005>. Adresse: <https://www.sciencedirect.com/science/article/pii/S0031320314000235>.
- [49] B. Benligiray, C. Topal und C. Akinlar, "STag: A stable fiducial marker system", *Image and Vision Computing*, Jg. 89, S. 158–169, 2019, ISSN: 0262-8856. DOI: 10.1016/j.imavis.2019.06.007.

Abbildungsverzeichnis

2.1	Vergleich der Koordinatensysteme [3]	3
2.2	Roll, Pitch und Yaw am Beispiel Holybro X650 [3]	4
2.3	Komponenten des Pixhawk 6X: FMU-Modul und Baseboard V2A [3]	10
3.1	Veranschaulichung des Loop-Closure-Effekts: (a) Reale Trajektorie ohne akkumulierten Fehler. (b) Geschätzte Trajektorie mit akkumuliertem Drift ohne Loop Closure. (c) Korrigierte Trajektorie nach Anwendung von Loop Closure mit reduziertem akkumuliertem Drift. vgl. [34]	16
3.2	Vereinfachter Faktorgraph eines SLAM-Problems, vgl. [35], [36], [37]	17
3.3	Übersicht gängiger Fiducial-Marker: a) ARTag; b) AprilTag; c) Aruco d) Stag [43], [44]	18

Tabellenverzeichnis

2.1 Sensorbestückung des Pixhawk 6X [18] 10

Quellcodeverzeichnis

10 Anhang

Der Anhang enthält ergänzende Informationen, die für das Verständnis der Arbeit relevant sind, aber nicht direkt in den Haupttext integriert werden konnten. Dazu gehören beispielsweise ausführliche Tabellen, zusätzliche Abbildungen oder Quellcode, der für die Implementierung der beschriebenen Methoden verwendet wurde.